Tests e2e d'API générés par IA

Un retour d'expérience en refonte legacy

23/04/2026

🎯 Le constat

Les tests de non-régression, un défi majeur en refonte legacy.

🔧 Le problème : refonte legacy et tests de non-régression

Comment s'assurer que la nouvelle API produit les mêmes résultats que l'ancienne ?

- **API legacy** : API historique utilisée depuis des années
- **API actual (nouvelle)** : Nouvelle implémentation avec architecture moderne
- **Contexte** : API massive et fortement exposée, migration longue
- **Objectif** : Migrer sans casser les fonctionnalités existantes

🔄 Le défi du double run testing

Principe simple : comparer les réponses des deux API

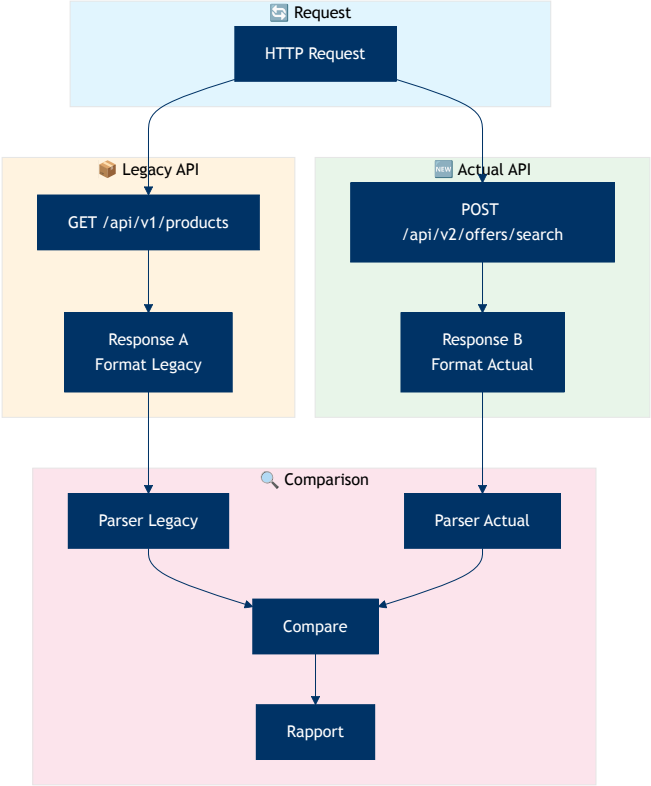

😥 Pourquoi c'est difficile

Différences de structure JSON

Legacy API	New API
`product.id`	`offer.productId`
`product.name`	`offer.title`
`product.price`	`offer.pricing.total`
`product.stock`	`offer.availability.quantity`

Problèmes rencontrés :

- Nommage des champs différent
- Structures imbriquées différentes
- Réponses JSON de 200KB+
- Champs optionnels vs obligatoires
- Payloads différents
- Enchaînements de requêtes parfois différents

🧠 L'opportunité IA : comprendre le sens

L'avantage de l'IA : comprendre le sens, pas seulement la structure

- Comprendre que `product.name` équivaut à `offer.title`
- Mapper automatiquement les champs équivalents
- Détecter les incohérences sémantiques
- Générer du code de transformation

L'exploration

Une quête pour trouver la bonne approche.

🧭 Notre parcours d'exploration

Outils explorés :

- **LLM** : Claude sonnet / opus, Gemini flash / pro, GLM, Qwen coder
- **RAG** : Preuve de concept sur une base de connaissances
- **MCP** : Model Context Protocol pour l'intégration d'outils
- **Playwright** : Automatisation de tests e2e
- **LangChain** : Workflows IA en TypeScript

Convergence vers une solution hybride

🛠️ Stack technique retenue

Composant	Solution	Rôle
Agent	Cline	Orchestration des workflows de génération
LLM	Claude Sonnet 4	Génération de code et analyse
Langage	TypeScript / Jest	Framework et tests
Configuration	YAML	DSL déclaratif
Protocole	MCP	Intégration avec les APIs

🤖 Architecture AI-First : concept

Un seul prompt pour tout gérer

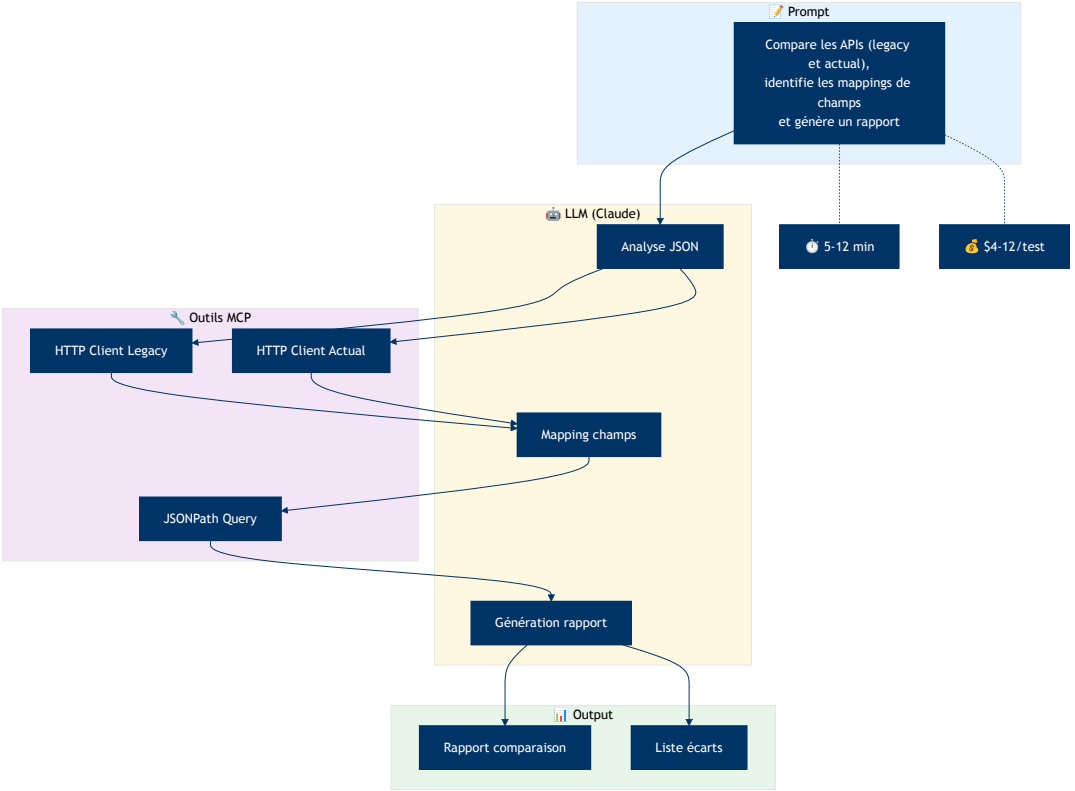

Architecture AI-First : fonctionnement

Tâches accomplies par l'IA :

1. **Appel API** : utilise un outil MCP pour consommer les APIs
2. **Analyse** : compare les structures JSON
3. **Mapping** : identifie les correspondances de champs
4. **Rapport** : génère un rapport de comparaison

Architecture AI-First : bilan

✅ Avantages	❌ Inconvénients
Un seul prompt complet	Taille et complexité du prompt
Simplicité de mise en œuvre	Un appel IA par test (coût)
Aucun code à maintenir	Exécution manuelle nécessaire (interaction inévitable)
Compréhension sémantique	Fiabilité non garantie

👉 **Bon pour l'exploration, pas pour l'industrialisation**

La solution

Une architecture DSL-Based.

⚙️ Architecture DSL-Based : concept

Moteur déterministe + plugins générés par IA

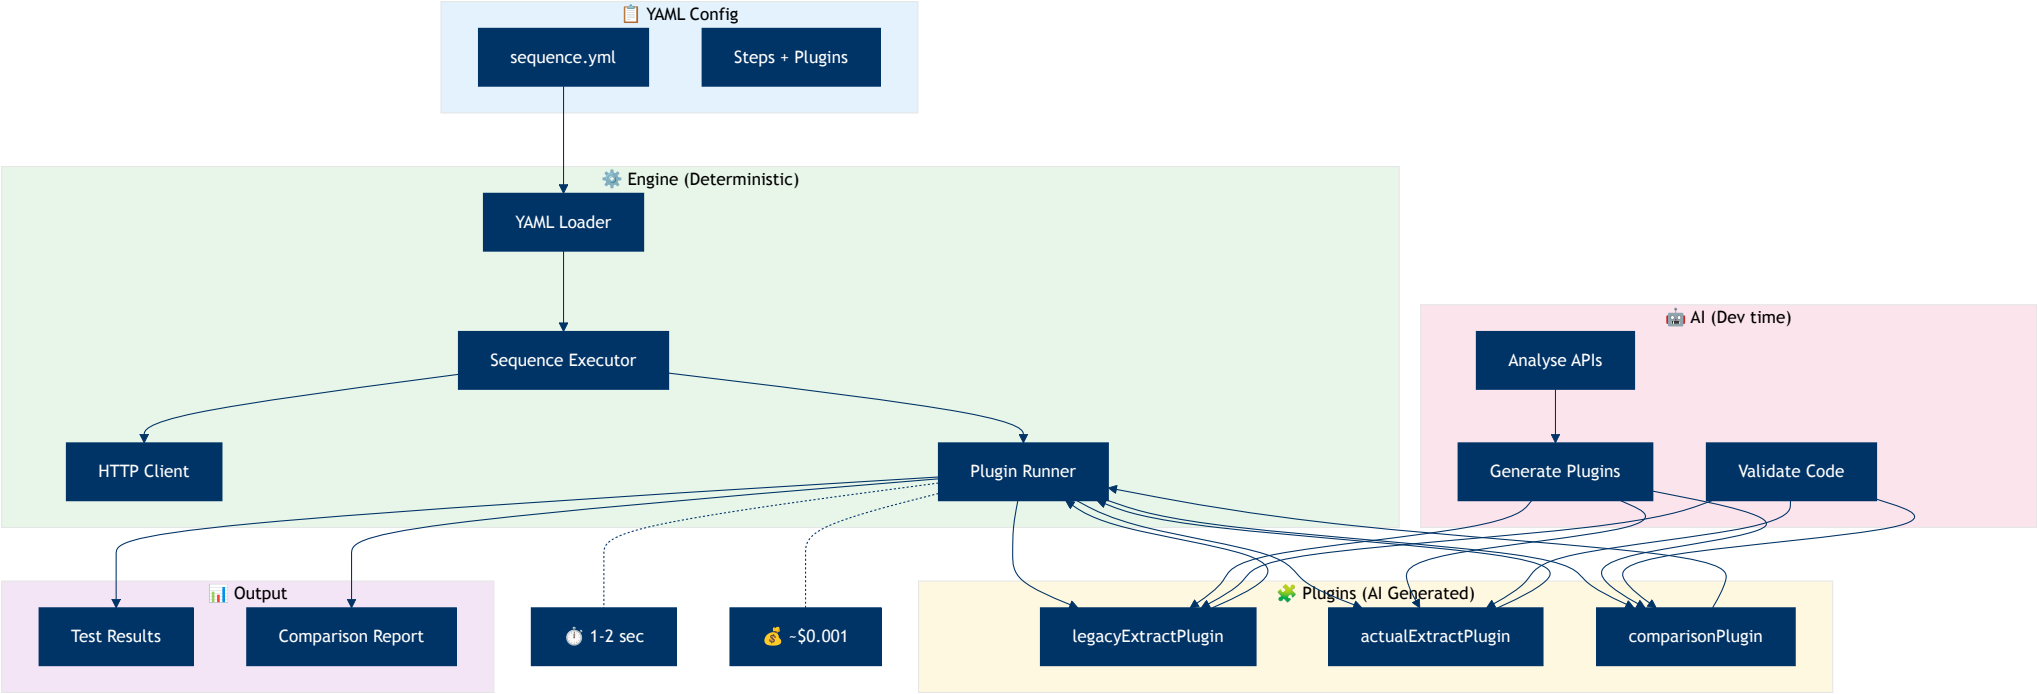

Architecture DSL-Based : fonctionnement

Deux phases :

1. **Phase de développement : l'IA**
   - Analyse les APIs (legacy et actual)
   - Génère les plugins de transformation
   - Génère les assertions de comparaison
2. **Phase d'exécution (déterministe) : le moteur**
   - Lit la configuration YAML
   - Exécute les requêtes HTTP
   - Applique les plugins
   - Produit le rapport

Le moteur de séquence YAML

```yaml
name: "Products to Offers Comparison"
steps:
  - name: legacy-products
    request:
      method: GET
      endpoint: "{{legacyBaseUrl}}/api/v1/products"
      headers:
        Accept: "application/json"
        X-Client-Id: "demo-client"
    plugins:
      - name: Extract legacy products
        type: legacyExtractPlugin
```

```yaml
  - name: actual-offers
    request:
      method: POST
      endpoint: "{{actualBaseUrl}}/api/v2/offers/search"
      headers:
        Content-Type: "application/json"
      payload:
        query:
          type: "product_search"
          filters:
            category: "all"
    plugins:
      - name: Extract actual offers
        type: actualExtractPlugin

  - name: comparison
    plugins:
      - name: Compare products vs offers
        type: productOfferComparisonPlugin
```

Système de plugins

Types de plugins :

Type	Rôle	Exemple
Extraction	Transformer les données	`legacyExtractPlugin`
Assertion	Vérifier des valeurs	`equalPlugin`
Comparaison	Comparer deux formats	`productOfferComparisonPlugin`

Génération par IA :

- Analyse les formats JSON
- Génère le code TypeScript du plugin
- Le plugin est intégré au moteur

🔄 Un format pivot

Un format commun pour comparer deux structures différentes

API legacy	Format pivot	API actual
`product.id`	→ `id`	`offer.productId`
`product.name`	→ `name`	`offer.title`
`product.price`	→ `price`	`offer.pricing.total`
`product.stock`	→ `stock`	`offer.availability.quantity`

Chaque plugin d'extraction transforme les données vers ce format commun

> 💡 *Contrat métier piloté par l'humain (→ « j'ai besoin de la catégorie maintenant »)*

📋 Architecture déléguée

Workflow de génération en 6 étapes

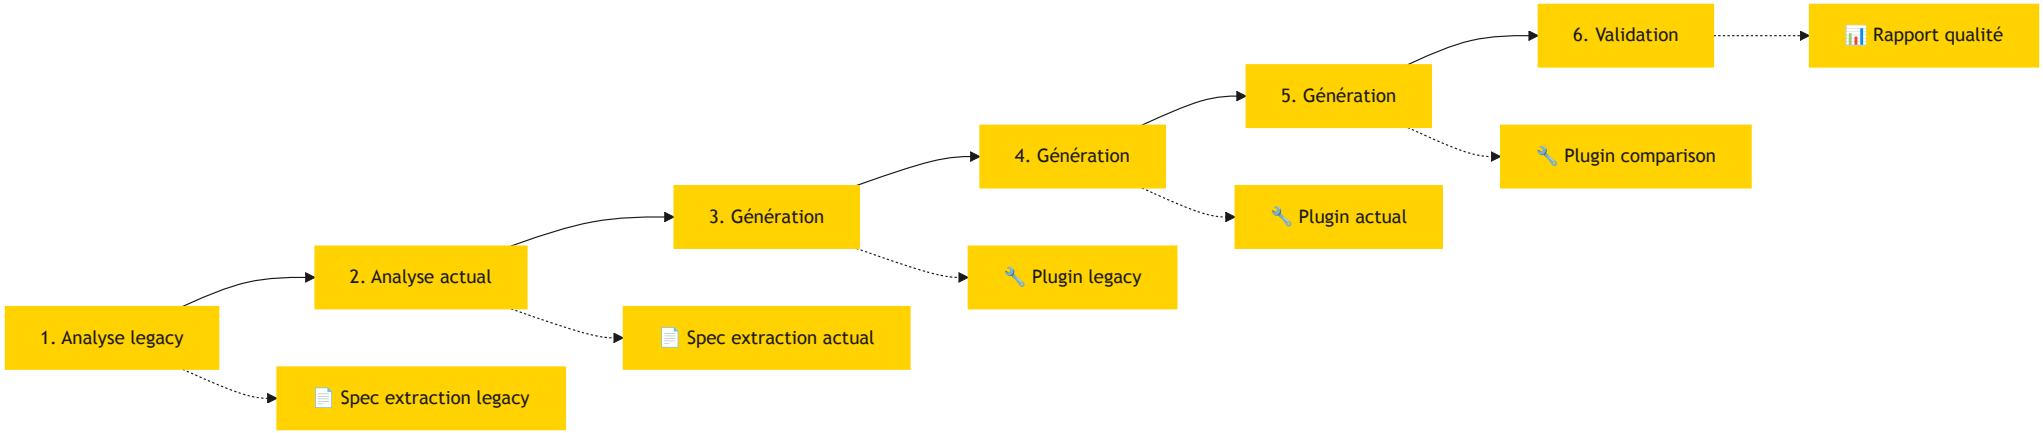

Avantage : validation par étape, contexte maîtrisé par tâche

💡 *6 workflows spécialisés et / ou un workflow qui orchestre le tout*

🎬 Démo

- Workflow de génération de plugins
- Comparaison API legacy vs actual
- Utilisation du harnais de tests

💡 Concepts émergents

Réflexions suite à l'expérience…

✂️ Les bienfaits du **découpage**

- ✅ Réduction de la complexité cognitive
- ✅ Validation progressive (fail fast)
- ✅ Reproductibilité des résultats
- ✅ Traçabilité et auditabilité
- ✅ Maintenance facilitée (scope limité)
- ✅ Fenêtre de contexte sous contrôle (évite ralentissements, hallucinations et plantages)
- ✅ Coût IA maîtrisé (contextes réduits = moins de retries et de gaspillage)

> 💡 *Chaque étape = un contrat vérifiable*
> 💡 *Temps passé à découper = investissement qui change la donne*

💡 IA et déterminisme : une question de temporalité

- L'IA n'est pas déterministe par nature
- Mais une fois validée par un process fiable, le résultat devient déterministe
- Combien de fois invoque-t-on l'IA dans un cycle ?
- Et si ce que produit l'IA est contrôlé par quelque chose de stable ?
- Que se passe-t-il si le contrôle est lui-même généré par IA ?

→ **Question de cycle / temporalité :**

- Le processus de contrôle se doit toujours d'être plus stable que le sujet du contrôle
- Peu importe qu'il émane d'un humain ou d'une IA, c'est la **confiance accumulée** qui compte

🎵 L'analogie du Jazz : la pulsation

En musique Jazz, l'improvisation repose sur un fondement solide :

Pulsation (beat, colonne vertébrale), harmonie (contexte), improvisation (liberté).

> *« L'improvisation, c'est la liberté surveillée ! »*
>
> — Didier Court (guitariste jazz)

Jazz	Projet IA
Pulsation	Checkpoints du workflow
Accords	Spécifications et formats
Improvisation	Tâches de génération

Vibe-coding : improviser sans cadre

Laisser l'IA improviser sans structure définie :

- ❌ Résultats imprévisibles
- ❌ Difficile à reproduire
- ❌ Pas de traçabilité
- ❌ Risque d'hallucination

Le risque : L'IA génère du code sans validation

Pulse-coding : cadre structuré avec checkpoints

Un cadre structuré avec des points de validation :

- ✅ Validation à chaque étape
- ✅ Reproductibilité garantie
- ✅ Traçabilité via Git
- ✅ Erreurs détectées tôt

> 💡 *La pulse : point de synchro non arbitrable qui cadence et jugule l'improvisation*

Bilan

✅ Ce qui a fonctionné

Architecture DSL-Based :

- Exécution rapide (1-2 secondes)
- Tests reproductibles
- Coût minimal à l'exécution
- Intégration CI/CD facile

Génération IA des plugins :

- Mapping automatique des champs
- Qualité du code : AAAA 🎯
- Maintenance facilitée

❌ Ce qui n'a pas fonctionné

Architecture AI-First :

- Trop lent pour les tests quotidiens
- Résultats parfois inconsistants
- Coût élevé pour beaucoup de tests

Défis généraux :

- Accès aux APIs de production délicat
- Gestion des environnements / données de test
- Budget IA qui explose sur des grosses sessions

🧩 Les défis techniques rencontrés

1. **JSON volumineux (200KB+)**
   - Solution : extraction JSONPath avant envoi à l'IA
2. **Compréhension du métier**
   - Solution : prompts avec exemples et contexte
3. **Double appel API**
   - Solution : mocks pour les tests reproductibles
4. **Instabilités**
   - Risque d'hallucination avec des modèles moins capables
   - Solution : mieux découper

Gestion des JSON volumineux

Problème : Fichiers de réponse de 200KB+ → fenêtre de contexte saturée

Solution : L'IA utilise le MCP `json-tools` pour interroger le JSON via JSONPath

❌ Sans MCP

L'IA reçoit tout le JSON dans son contexte

✅ Avec MCP `json-tools`

L'IA interroge uniquement ce dont elle a besoin

Bénéfice : L'IA comprend la structure sans jamais charger la collection entière

Coûts et performance comparés

Métrique	AI-First	DSL-Based
Temps par test	5-12 minutes	1-2 secondes
Coût de mise en œuvre	0	~$2
Coût par test	$4-12	0
Reproductibilité	Variable	100%
Maintenance prompts	Élevée	Faible
Intégration CI/CD	Difficile	Facile

ROI : DSL-Based payant après quelques tests

📊 KPI IA (Claude Sonnet)

5 étapes, ~15 minutes, ~$2 au total

Étape	Rôle	Tokens	Coût	Durée
1	Analyse Legacy	52k	$0.33	2-4 min
2	Analyse Actual	21k	$0.23	2-4 min
3	Plugin Legacy	74k	$0.49	2-4 min
4	Plugin Actual	32k	$0.40	2-4 min
5	Plugin Comparison	45k	$0.43	2-4 min
Total		**224k**	**~$2**	**~15 min**

💡 *Coût one-shot de mise en œuvre — ensuite, exécution déterministe à coût nul*

Courbe d'apprentissage de l'équipe

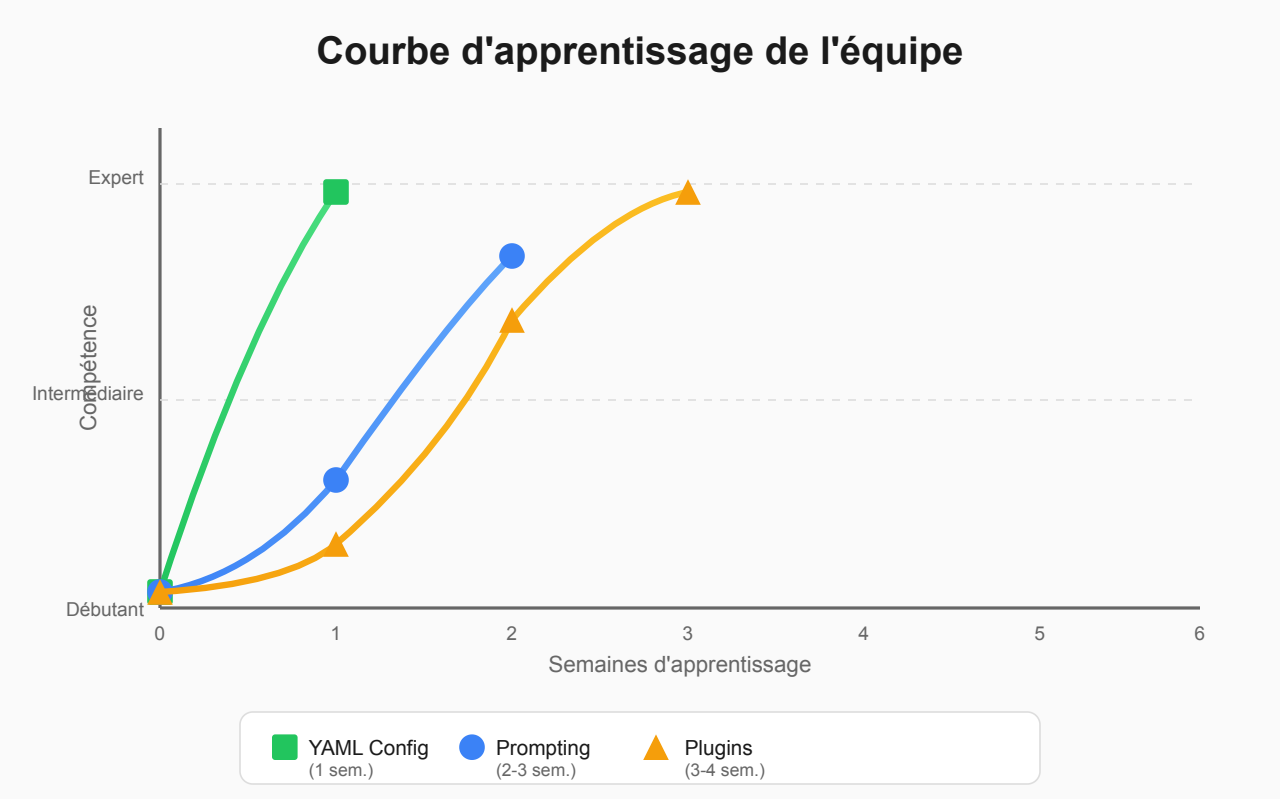

Trois approches de test

Approche	Écriture	Maintenance	Couverture
Tests manuels	Exécution à la main	Fastidieuse	Limitée
Tests automatisés codés	Code écrit à la main	Coûteuse	Bonne
Tests automatisés générés par IA	Génération assistée	Facilitée	Étendue

Conviction :

- Générer des tests automatisés par IA
- Avec validation développeur ou QA
- La validation ne porte que sur les deltas, dans un scope délimité

👉 Stratégie efficiente

Maintenance et évolution

Quand l'API change :

1. **Nouveau champ** → Régénérer le plugin (5 min)
2. **Champ renommé** → Mettre à jour le mapping (2 min)
3. **Nouvel endpoint** → Ajouter une étape YAML (10 min)

Processus :

- L'IA propose les modifications
- Le développeur valide
- Les tests confirment

Quand utiliser AI-First vs DSL-Based

AI-First :

- Exploration ponctuelle
- Prototypage rapide
- Analyse de nouvelles APIs
- Dépannage ponctuel

DSL-Based :

- Tests de régression quotidiens
- Intégration CI/CD
- Tests de charge
- Environnements multiples

Critères de choix

Critère	AI-First	DSL-Based
Fréquence d'exécution	Occasionnelle	Quotidienne
Budget	Flexible	Contraint
Reproductibilité	Non critique	Critique
Intégration CI	Non	Oui
Expertise équipe	Prompting++	Prompting et dev light

⚠️ Pièges à éviter

1. **Ignorer la validation humaine**
   - Toujours relire le code généré
2. **Tests non reproductibles**
   - Utiliser des mocks réalistes
3. **Prompts trop complexes**
   - Diviser en tâches simples
4. **Ignorer la performance**
   - Mesurer le temps d'exécution
5. **Oublier la documentation**
   - Documenter les mappings et décisions

Prochaines étapes pour notre projet

1. **Industrialiser le framework DSL-Based**
   - CI/CD complet
   - Intégrer les pratiques dans le quotidien des équipes QA
2. **Étendre la couverture**
   - Nouveaux endpoints
   - Nouveaux cas d'usage
3. **Capitaliser sur l'apprentissage**
   - Partage des bonnes pratiques
   - Ateliers internes

🎉 Conclusion

- Solution relativement éprouvée
- Leçons apprises
- Bonne appropriation (QA)
- Encourageant pour une généralisation

🤙 Merci !

Questions / remarques / réactions ? 😊

Contacts :

- cyrille.martraire@arolla.fr
- olivier.penhoat@arolla.fr

GitHub : https://github.com/openhoat/devoxx2026